

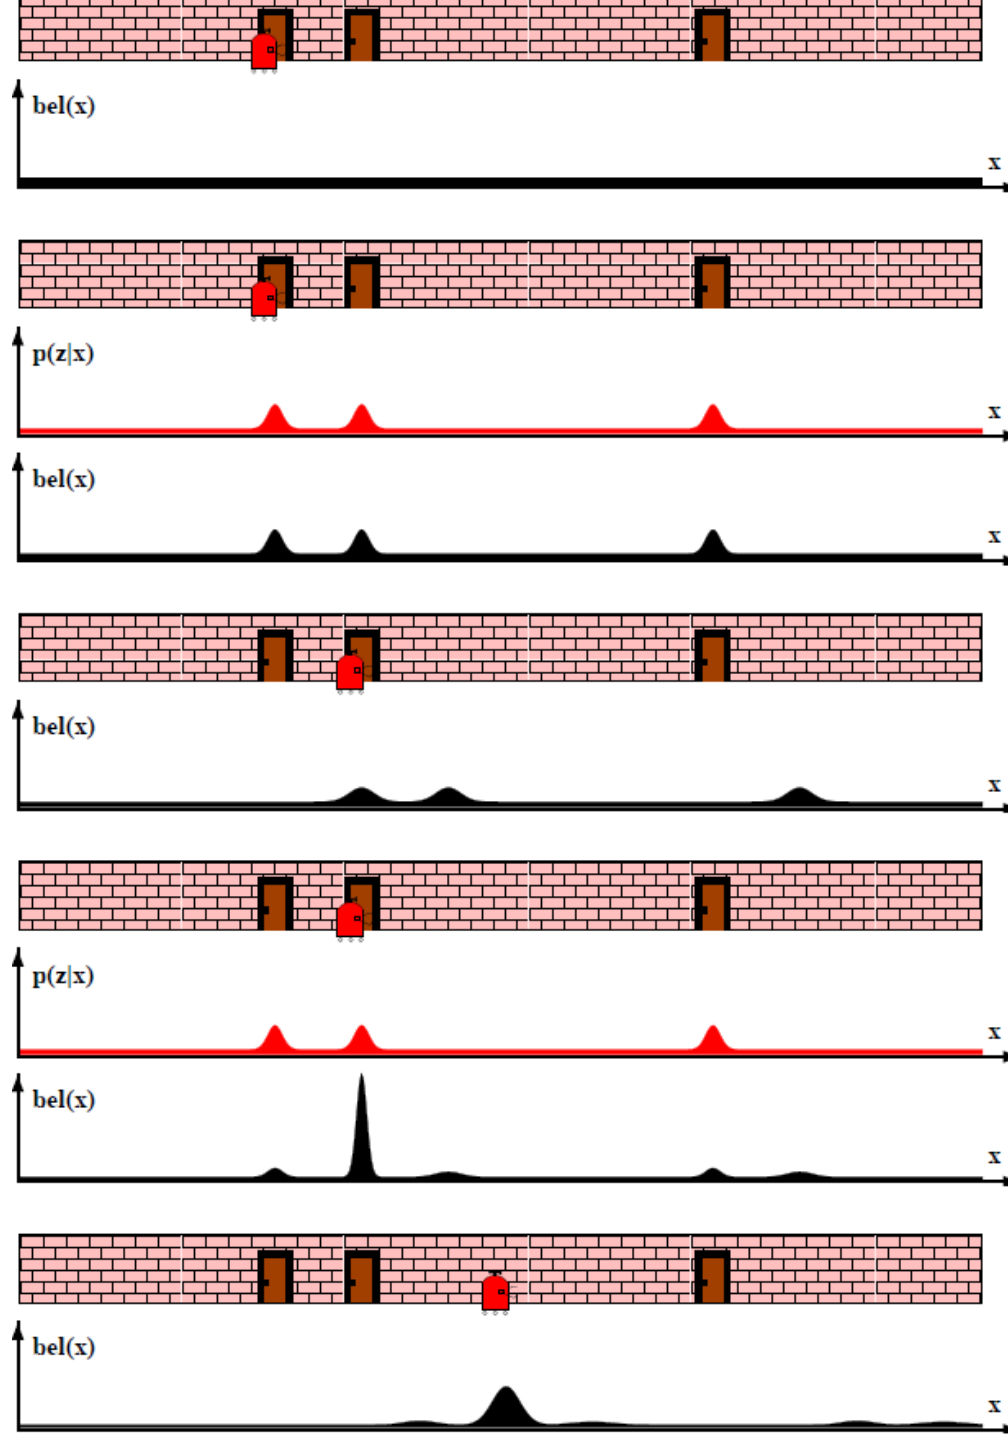
Машинное обучение в робототехнике

Вероятностный подход. Модели Гаусса

Факторы неопределенности

- Окружающая среда
- Датчики
- Роботы
- Модели
- Вычисления

Пример



Обозначения

$p(X = x) \geq 0$ – вероятность, что случайная величина X примет значение x , $\sum_x p(X = x) = 1$. Для краткости $p(x)$.

μ – математическое ожидание случайной величины

σ – среднеквадратическое отклонение

σ^2 - дисперсия случайной величины

Условная вероятность: $p(x|y) = \frac{p(x,y)}{p(y)}$

Формула Байеса:



$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} = \frac{p(y|x)p(x)}{\sum_{x'} p(y|x')p(x')}$$

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} = \frac{p(y|x)p(x)}{\int p(y|x')p(x')dx'}$$

Нормальное распределение (Гаусса)

Будем считать, что непрерывные случайные величины имеют нормальную функцию распределения плотности вероятности.



$$p(x) = (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{1}{2} \frac{(x - \mu)^2}{\sigma^2} \right\}$$





Нормальное распределение (Гаусса)

- Только два параметра функции плотности для вычисления: математическое ожидание и стандартное отклонение
- Полезные свойства: произведение распределений Гаусса формирует распределение Гаусса
- Центральная предельная теорема: Ожидание среднего большого числа случайных чисел сходится к распределению Гаусса
- Моделирование шумов и неопределенностей

Нормальное распределение (Гаусса)



Обнаружение мяча



Локализация робота

Оценка максимального правдоподобия

Функция правдоподобия— это совместное распределение выборки из параметрического распределения, рассматриваемое как функция параметра.

$$p(\{x_i\}|\mu, \sigma)$$

Задача:

$$\hat{\mu}, \hat{\sigma} = \arg \max p(\{x_i\}|\mu, \sigma)$$

Оценка максимального правдоподобия

Функция правдоподобия— это совместное распределение выборки из параметрического распределения, рассматриваемое как функция параметра.

$$p(\{x_i\}|\mu, \sigma)$$

Задача:

$$\hat{\mu}, \hat{\sigma} = \arg \max p(\{x_i\}|\mu, \sigma)$$

Будем считать измерения независимыми:


$$p(\{x_i\}|\mu, \sigma) = \prod_{i=1}^N p(x_i|\mu, \sigma)$$

$$\hat{\mu}, \hat{\sigma} = \arg \max \prod_{i=1}^N p(x_i|\mu, \sigma)$$

Оценка максимального правдоподобия

Функция логарифма монотонно возрастает

$$\begin{aligned} \arg \max_{\mu, \sigma} \prod_{i=1}^N p(x_i | \mu, \sigma) &= \arg \max_{\mu, \sigma} \ln \left[\prod_{i=1}^N p(x_i | \mu, \sigma) \right] = \\ &= \arg \max_{\mu, \sigma} \sum_{i=1}^N \ln p(x_i | \mu, \sigma) \end{aligned}$$



Оценка максимального правдоподобия

$$\begin{aligned}\ln p(x_i|\mu, \sigma) &= \ln(2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right\} = \\ &= -\frac{(x-\mu)^2}{2\sigma^2} - \ln \sigma - \ln \sqrt{2\pi}\end{aligned}$$

Оценка максимального правдоподобия

$$\begin{aligned}\ln p(x_i|\mu, \sigma) &= \ln(2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right\} = \\ &= -\frac{(x-\mu)^2}{2\sigma^2} - \ln \sigma - \ln \sqrt{2\pi} \\ \arg \max_{\mu, \sigma} \sum_{i=1}^N \ln p(x_i|\mu, \sigma) &= \arg \max_{\mu, \sigma} \sum_{i=1}^N \left[-\frac{(x-\mu)^2}{2\sigma^2} - \ln \sigma - \ln \sqrt{2\pi} \right] \\ &= \arg \max_{\mu, \sigma} \sum_{i=1}^N \left[-\frac{(x-\mu)^2}{2\sigma^2} - \ln \sigma \right]\end{aligned}$$

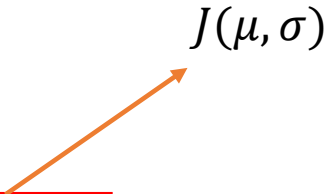
Оценка максимального правдоподобия

Перейдем от задачи максимизации к задаче минимизации

$$\arg \max_{\mu, \sigma} \sum_{i=1}^N \left[-\frac{(x - \mu)^2}{2\sigma^2} - \ln \sigma \right] \Rightarrow \arg \min_{\mu, \sigma} \sum_{i=1}^N \left[\frac{(x - \mu)^2}{2\sigma^2} + \ln \sigma \right]$$

Оценка максимального правдоподобия

Перейдем от задачи максимизации к задаче минимизации

$$\arg \max_{\mu, \sigma} \sum_{i=1}^N \left[-\frac{(x_i - \mu)^2}{2\sigma^2} - \ln \sigma \right] \Rightarrow \arg \min_{\mu, \sigma} \sum_{i=1}^N \left[\frac{(x_i - \mu)^2}{2\sigma^2} + \ln \sigma \right]$$


Аналитическое решение:

$$\begin{aligned} \frac{\partial J}{\partial \mu} = 0 &\rightarrow \hat{\mu} & \frac{\partial J}{\partial \sigma} = 0 &\rightarrow \hat{\sigma} \\ \hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i & & \hat{\sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})^2 \end{aligned}$$

Многомерный гауссиан

В векторном случае

$$p(x) = \det(2\pi\Sigma)^{-1/2} \exp\left\{-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right\},$$

где Σ - положительная полуопределенная симметричная матрица ковариации

Пример матрицы ковариации для второго порядка:

$$\Sigma = \begin{bmatrix} \sigma_{x_1}^2 & \sigma_{x_1} \sigma_{x_2} \\ \sigma_{x_2} \sigma_{x_1} & \sigma_{x_2}^2 \end{bmatrix}$$

Оценка многомерного гауссиана

Задача:

$$\hat{\mu}, \hat{\Sigma} = \arg \max_{\mu, \Sigma} p(\{x_i\} | \mu, \Sigma)$$

Будем считать измерения независимыми:

$$\hat{\mu}, \hat{\Sigma} = \arg \max_{\mu, \Sigma} \prod_{i=1}^N p(x_i | \mu, \Sigma)$$

Применим логарифм

$$\arg \max_{\mu, \Sigma} \prod_{i=1}^N p(x_i | \mu, \Sigma) = \arg \max_{\mu, \Sigma} \sum_{i=1}^N \ln p(x_i | \mu, \Sigma)$$

Оценка многомерного гауссиана

$$\hat{\mu}, \hat{\Sigma} = \arg \max_{\mu, \Sigma} \sum_{i=1}^N \ln p(x_i | \mu, \Sigma)$$

$$\ln p(x_i | \mu, \Sigma) = -\frac{1}{2} (x_i - \mu)^T \Sigma^{-1} (x_i - \mu) - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} \ln 2\pi$$



$$\hat{\mu}, \hat{\Sigma} = \arg \min_{\mu, \Sigma} \sum_{i=1}^N \frac{1}{2} (x_i - \mu)^T \Sigma^{-1} (x_i - \mu) - \frac{1}{2} \ln |\Sigma|$$

Оценка многомерного гауссиана

Аналитическое решение:

$$\begin{aligned} \frac{\partial J}{\partial \mu} = 0 &\rightarrow \hat{\mu} & \frac{\partial J(\hat{\mu}, \Sigma)}{\partial \Sigma} = 0 &\rightarrow \hat{\Sigma} \\ \hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i & & \hat{\Sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \end{aligned}$$

Смешение гауссианов



$$p(x) = \sum_{k=1}^K w_k g_k(x|\mu_k, \Sigma_k), w_k > 0, \sum_{k=1}^K w_k = 1$$

Параметры: множество μ и Σ , w

Смешение гауссианов. Максимизация ожидания (Expectation maximization)

Для простоты будем считать

k - известно, $w = 1/k$

Задача:

$$\hat{\mu}, \hat{\Sigma} = \arg \max_{\mu, \Sigma} p(\{x_i\} | \mu, \Sigma), \mu = \{\mu_k\}, \Sigma = \{\Sigma_k\}$$

$$\hat{\mu}, \hat{\Sigma} = \arg \max_{\mu, \Sigma} \sum_{i=1}^N \ln \left[\frac{1}{k} \sum_{k=1}^K g_k(x_i | \mu_k, \Sigma_k) \right]$$

Аналитического решения не существует.

Но есть локально оптимальное.

Смещение гауссианов. Максимизация ожидания (Expectation maximization)

- 1) Задаем начальные μ и Σ .
- 2) Рассчитываем вспомогательные переменные

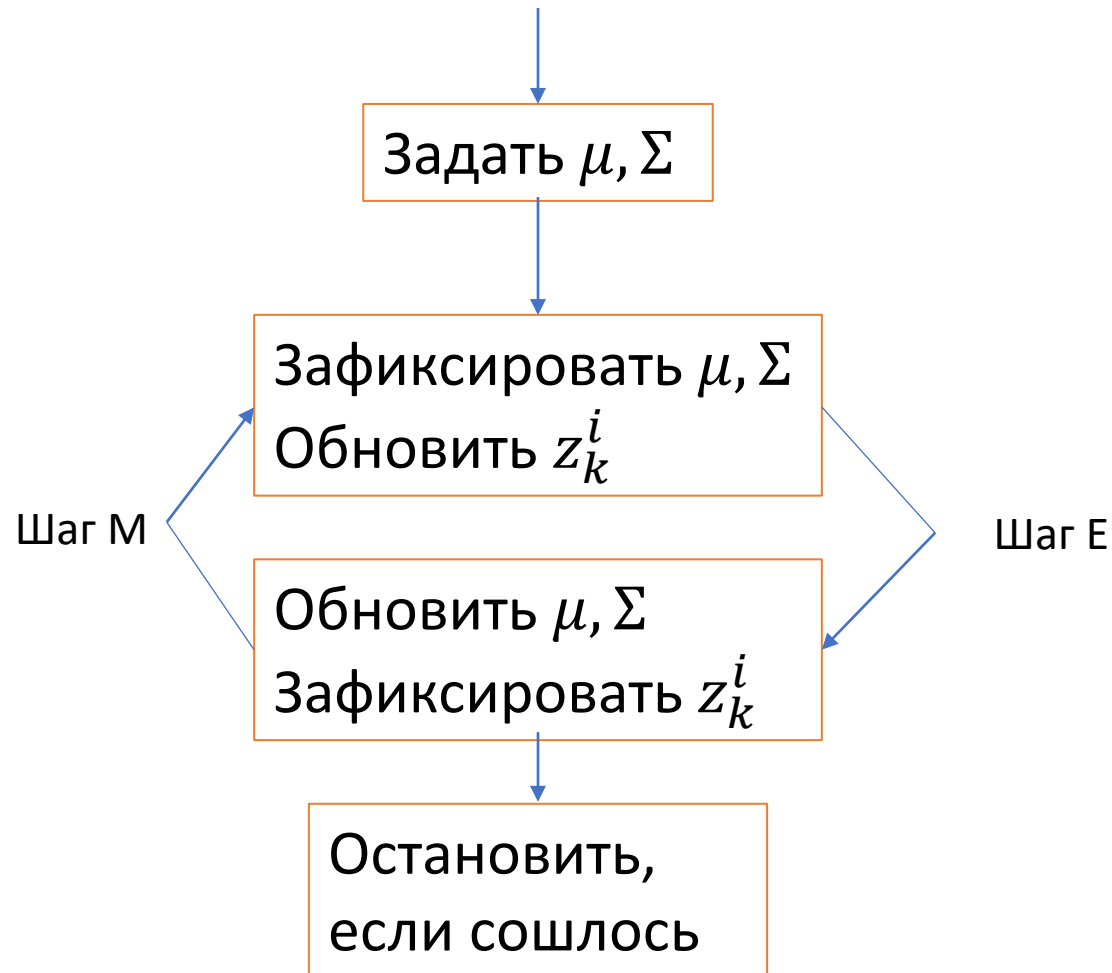
$$z_k^i = \frac{g_k(x_i | \mu_k, \Sigma_k)}{\sum_{k=1}^K g_k(x_i | \mu_k, \Sigma_k)}, z_k = \sum_{i=1}^N z_k^i$$

- 3) Итеративно рассчитываем:

$$\hat{\mu} = \frac{1}{z_k} \sum_{i=1}^N z_k^i x_i, \hat{\Sigma}_k = \frac{1}{z_k} \sum_{i=1}^N z_k^i (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$$

- 4) Возвращаемся на шаг 2, если сходимость не достигнута

Смешение гауссианов. Максимизация ожидания (Expectation maximization)



Робот и окружение

Состояние $x_t = x_{t_1:t_2} = x_{t_1}, x_{t_1+1}, \dots, x_{t_2}$

- Положение
- Конфигурация исполнительных механизмов
- Скорости
- Расположение и особенности окружающих предметов
- Расположение и скорости подвижных объектов
- Уровень заряда батареи, состояние датчиков, износ и т.д.

Робот и окружение

Взаимодействие

- Измерения датчиков
- Сигналы управления
- Данные всех измерений $z_t = z_{t_1:t_2} = z_{t_1}, z_{t_1+1}, \dots, z_{t_2}$
- Данные управления $u_t = u_{t_1:t_2} = u_{t_1}, u_{t_1+1}, \dots, u_{t_2}$

Эволюция состояния робота

$$p(x_t | x_{0:t-1}, z_{1:t-1}, u_{1:t})$$

Пусть данные датчиков не влияют на состояние:

$$p(x_t | x_{0:t-1}, z_{1:t-1}, u_{1:t}) = p(x_t | x_{t-1}, u_t)$$

Данные датчиков:

$$p(z_t | x_{0:t}, z_{1:t-1}, u_{1:t}) = p(z_t | x_t)$$

Вероятность состояния робота

Апостериорное распределение плотности вероятности (belief)

$$bel(x_t) = p(x_t | z_{1:t}, u_{1:t})$$

Ожидаемое распределение плотности вероятности

$$\overline{bel}(x_t) = p(x_t | z_{1:t-1}, u_{1:t})$$

$bel(x_t)$ является откорректированным предсказанием $\overline{bel}(x_t)$

Фильтр Байеса

```
1:  Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:    for all  $x_t$  do  
3:       $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:       $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:    endfor  
6:    return  $bel(x_t)$ 
```

Фильтр Байеса. Пример

- Будем считать вероятность открытой двери в начальный момент времени 0.5

$$\text{bel}(X_0 = \text{open}) = 0.5$$

$$\text{bel}(X_0 = \text{closed}) = 0.5$$


- Будем считать, что показания датчиков зашумлены.

$$p(Z_t = \text{sense_open} | X_t = \text{is_open}) = 0.6$$

$$p(Z_t = \text{sense_closed} | X_t = \text{is_open}) = 0.4$$

$$p(Z_t = \text{sense_open} | X_t = \text{is_closed}) = 0.2$$


$$p(Z_t = \text{sense_closed} | X_t = \text{is_closed}) = 0.8$$



Фильтр Байеса. Пример

$$\begin{aligned}p(X_t = is_open | U_t = push, X_{t-1} = is_open) &= 1 \\p(X_t = is_closed | U_t = push, X_{t-1} = is_open) &= 0 \\p(X_t = is_open | U_t = push, X_{t-1} = is_closed) &= 0.8 \\p(X_t = is_closed | U_t = push, X_{t-1} = is_closed) &= 0.2\end{aligned}$$

$$\begin{aligned}p(X_t = is_open | U_t = no, X_{t-1} = is_open) &= 1 \\p(X_t = is_closed | U_t = no, X_{t-1} = is_open) &= 0 \\p(X_t = is_open | U_t = no, X_{t-1} = is_closed) &= 0 \\p(X_t = is_closed | U_t = no, X_{t-1} = is_closed) &= 1\end{aligned}$$



Фильтр Байеса. Пример

Робот не движется. Дверь открыта

$$\begin{aligned}\overline{bel}(x_1) &= \int p(x_1|u_1, x_0)bel(x_0)dx_0 = \sum_{x_0} p(x_1|u_1, x_0)bel(x_0) = \\ &= p(x_1|U_1 = do_nothing, X_0 = is_open)bel(X_0 = is_open) \\ &+ p(x_1|U_1 = do_nothing, X_0 = is_closed)bel(X_0 = is_closed) = 0.5\end{aligned}$$

$$\begin{aligned}\overline{bel}(X_1 = is_open) &= 0.5 \\ \overline{bel}(X_1 = is_closed) &= 0.5\end{aligned}$$

Фильтр Байеса. Пример

$$bel(x_1) = \eta p(Z_1 = sense_open | x_1) \overline{bel}(x_1)$$

$$bel(X_1 = is_open) = \eta p(Z_1 = sense_open | X_1 = is_open) \overline{bel}(X_1 = is_open)$$

$$bel(X_1 = is_open) = \eta 0.6 * 0.5 = \eta 0.3$$

$$bel(X_1 = is_closed) = \eta p(Z_1 = sense_open | X_1 = is_open) \overline{bel}(X_1 = is_open)$$

$$bel(X_1 = is_closed) = \eta 0.2 * 0.5 = \eta 0.1$$

$$\eta = \frac{1}{0.3 + 0.1} = 2.5$$

$$bel(X_1 = is_open) = 0.75$$

$$bel(X_1 = is_closed) = 0.25$$

Фильтр Байеса. Пример

В момент времени 2 толкнем дверь, датчик показал $Z_2 = \textit{sense_open}$

$$\overline{bel}(X_2 = \textit{is_open}) = 1 * 0.75 + 0.8 * 0.25 = 0.95$$

$$\overline{bel}(X_2 = \textit{is_closed}) = 0 * 0.75 + 0.2 * 0.25 = 0.05$$

$$bel(X_2 = \textit{is_open}) = \eta 0.6 * 0.95 \approx 0.983$$

$$bel(X_2 = \textit{is_closed}) = \eta 0.2 * 0.05 \approx 0.017$$

Фильтр Байеса. Обоснование

Формула Байеса:

$$p(x_t | z_{1:t}, u_{1:t}) = \frac{p(z_t | x_t, z_{1:t-1}, u_{1:t}) p(x_t | z_{1:t-1}, u_{1:t})}{p(z_t | z_{1:t-1}, u_{1:t})}$$

$$p(x_t | z_{1:t}, u_{1:t}) = \eta p(z_t | x_t, z_{1:t-1}, u_{1:t}) p(x_t | z_{1:t-1}, u_{1:t})$$

Фильтр Байеса. Обоснование

При полноте состояния

$$p(z_t | x_t, z_{1:t-1}, u_{1:t}) = p(z_t | x_t)$$

$$p(x_t | z_{1:t}, u_{1:t}) = \eta p(z_t | x_t) p(x_t | z_{1:t-1}, u_{1:t})$$

Перепишем в терминах *bel*

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

Фильтр Байеса. Обоснование

При пол

```
1: Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:   for all  $x_t$  do  
3:      $\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:      $bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$   
5:   endfor  
6:   return  $bel(x_t)$ 
```

Перепишем в терминах bel

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

Фильтр Байеса. Обоснование

Раскроем $\overline{bel}(x_t)$

$$\begin{aligned}\overline{bel}(x_t) &= p(x_t | z_{1:t-1}, u_{1:t}) = \\ &= \int p(x_t | x_{t-1}, z_{1:t-1}, u_{1:t}) p(x_{t-1} | z_{1:t-1}, u_{1:t}) dx_{t-1}\end{aligned}$$

$$p(x_{t-1} | z_{1:t-1}, u_{1:t}) = p(x_{t-1} | z_{1:t-1}, u_{1:t-1})$$

$$\overline{bel}(x_t) = \int p(x_t | x_{t-1}, u_t) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1}$$

Фильтр Байеса. Обоснование

Раскроем $\overline{bel}(x_t)$

```
1:   Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:     for all  $x_t$  do  
3:        $\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:        $bel(x_t) = \eta p(z_t | x_t) bel(x_t)$   
5:     endfor  
6:     return  $bel(x_t)$ 
```

$$\overline{bel}(x_t) = \int p(x_t | x_{t-1}, u_t) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1}$$

Фильтр Байеса. Марковские процессы

Нарушающие факторы:

- Неучтенная динамика
- Неточности вероятностных моделей $p(z_t|x_t), p(x_t|u_t, x_{t-1})$
- Ошибки аппроксимации
- Влияние переменных на выбор управления

Фильтр Байеса. Вопросы реализации

- Вычислительная эффективность
- Точность аппроксимации
- Простота реализации

Заключение

- Робот и окружение моделируются как связанная динамическая система
- Динамика описывается вероятностными законами
- Фильтр Байеса – основной алгоритм постериорного расчета в робототехнике
- Фильтр Байеса требует соблюдения условий Маркова
- Для реализации фильтра Байеса используются аппроксимации