


Машинное обучение в робототехнике

Фильтры для локализации роботов

Проблематика

- Имеется множество измерений движущегося объекта
- Все измерения зашумлены
- Где на самом деле находится объект?



Модель объекта

Движение описывается линейной дискретной системой

$$\begin{aligned}x_{t+1} &= Ax_t + Bu_t \\ z_t &= Cx_t\end{aligned}$$


Вектор состояния:

$$x_{t+1}^T = [s \quad ds/dt]$$

Динамика:

$$A = \begin{bmatrix} 1 & dt \\ 0 & 1 \end{bmatrix}$$

Модель объекта



- Требуется x_t
- Известен x_{t-1}
- Известен z_t

Вероятностная модель

- Предсказание с учетом состояния динамической модели

$$p(x_{t+1}|x_t)$$

- Учет зашумленности измерений

$$p(z_t|x_t)$$

- Моделирование x_t как гауссиана (мат. ожидание и ковариация)

$$p(x_t) = N(x_t, P_t)$$

Вероятностная модель

- Используем линейную динамическую модель

$$\begin{aligned}p(x_{t+1}|x_t) &= Ap(x_t) \\ p(z_t|x_t) &= Cp(x_t)\end{aligned}$$

- Добавим шумы

$$\begin{aligned}p(x_{t+1}|x_t) &= Ap(x_t) + v_m \\ p(z_t|x_t) &= Cp(x_t) + v_o\end{aligned}$$

- Гауссиан x_t :

$$\begin{aligned}p(x_{t+1}|x_t) &= AN(x_t, P_t) + N(0, \Sigma_m) \\ p(z_t|x_t) &= CN(x_t, P_t) + N(0, \Sigma_o)\end{aligned}$$

Вероятностная модель

$$\begin{aligned}p(x_{t+1}|x_t) &= AN(x_t, P_t) + N(0, \Sigma_m) \\p(z_t|x_t) &= CN(x_t, P_t) + N(0, \Sigma_o)\end{aligned}$$

Выполним линейное преобразование распределений Гаусса:

$$\begin{aligned}p(x_{t+1}|x_t) &= N(Ax_t, AP_tA^T) + N(0, \Sigma_m) \\p(z_t|x_t) &= N(Cx_t, CP_tC^T) + N(0, \Sigma_o)\end{aligned}$$

Просуммируем гауссианы:

$$\begin{aligned}p(x_{t+1}|x_t) &= N(Ax_t, AP_tA^T + \Sigma_m) \\p(z_t|x_t) &= N(Cx_t, CP_tC^T + \Sigma_o)\end{aligned}$$

Максимизация апостериорной оценки

- Применить подход максимальной апостериорной (MAP) оценки по правилу Байеса
- Решить задачу максимизации
- Метод обновления параметров на основе фильтра Калмана

Байесовская фильтрация

- Правило Байеса:

$$p(\alpha|\beta) = \frac{p(\beta|\alpha)p(\alpha)}{p(\beta)}$$

- Вероятностная модель

$$p(x_{t+1}|x_t) = N(Ax_t, AP_tA^T + \Sigma_m)$$

$$p(z_t|x_t) = N(Cx_t, CP_tC^T + \Sigma_o)$$

Байесовская фильтрация

- Правило Байеса:

$$p(\alpha|\beta) = \frac{p(\beta|\alpha)p(\alpha)}{p(\beta)}$$

- Вероятностная модель

$$p(x_{t+1}|x_t) = N(Ax_t, AP_tA^T + \Sigma_m) \rightarrow \alpha \text{ априорная}$$

$$p(z_t|x_t) = N(Cx_t, CP_tC^T + \Sigma_o) \rightarrow \beta|\alpha \text{ правдоподобие}$$

$$\text{постериорная} \quad p(x_t|z_t, x_{t-1}) = \frac{p(z_t|x_t, x_{t-1})p(x_t|x_{t-1})}{p(z_t)}$$

Байесовская фильтрация

- Постериорное распределение – гауссиан
- MAP оценивает «оптимальное» x_t
- Использование MAP дает новое математическое ожидание и дисперсию состояния

MAP

Задача:

$$\hat{x}_t = \arg \max_{x_t} p(x_t | z_t, x_{t-1})$$
$$\hat{x}_t = \arg \max_{x_t} \frac{p(z_t | x_t) p(x_t | x_{t-1})}{p(z_t)}$$

$$\hat{x}_t = \arg \max_{x_t} p(z_t | x_t) p(x_t | x_{t-1})$$

$$\hat{x}_t = \arg \max_{x_t} N(Cx_t, CP_t C^T + \Sigma_0) N(Ax_{t-1}, AP_{t-1} A^T + \Sigma_m)$$

MAP

$$\hat{x}_t = \arg \max_{x_t} N(Cx_t, CP_tC^T + \Sigma_0)N(Ax_{t-1}, AP_{t-1}A^T + \Sigma_m)$$

Введем замену переменных:

$$P = P_t = AP_{t-1}A^T + \Sigma_m$$
$$R = CP_tC^T + \Sigma_0$$

Возьмем логарифм и перейдем к задаче минимизации

$$\hat{x}_t = \arg \min_{x_t} (z_t - Cx_t)R^{-1}(z_t - Cx_t)^T + (x_t - Ax_{t-1})P^{-1}(x_t - Ax_{t-1})^T$$

MAP

Аналитическое решение:

$$\hat{x}_t = \arg \min_{x_t} (z_t - Cx_t)R^{-1}(z_t - Cx_t)^T + (x_t - Ax_{t-1})P^{-1}(x_t - Ax_{t-1})^T$$

$$0 = \frac{d}{dx_t} \left((z_t - Cx_t)R^{-1}(z_t - Cx_t)^T + (x_t - Ax_{t-1})P^{-1}(x_t - Ax_{t-1})^T \right)$$

MAP

Приведем подобные

$$\begin{aligned}(C^T R^{-1} C + P^{-1})x_t &= z_t^T R^{-1} C + P^{-1} A x_{t-1} \\ x_t &= (C^T R^{-1} C + P^{-1})^{-1} (z_t^T R^{-1} C + P^{-1} A x_{t-1})\end{aligned}$$

С учетом леммы об обратной матрице:

$$(C^T R^{-1} C + P^{-1})^{-1} = P - P C^T (R + C P C^T)^{-1} C P$$

Обозначим множитель Калмана:

$$K = P C^T (R + C P C^T)^{-1}$$

Фильтр Калмана

Результат:

$$K = PC^T R^{-1} - KCP C^T R$$
$$\hat{x}_t = Ax_{t-1} + K(z_t - CAx_{t-1})$$

Обновление ковариации:

$$\hat{P}_t = P - KCP$$

При наличии управления:

$$\hat{x}_t = Ax_{t-1} + K(z_t - CAx_{t-1}) + (I - KC)Bu_t$$

Фильтр Калмана

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t \quad R_t\text{- ковариация } \varepsilon_t$$

$$z_t = C_t x_t + \delta_t \quad Q_t\text{- ковариация } \delta_t$$

```
1:  Algorithm Kalman_filter( $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$ ):  
2:       $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$   
3:       $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t$   
4:       $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$   
5:       $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$   
6:       $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$   
7:      return  $\mu_t, \Sigma_t$ 
```

Расширенный фильтр Калмана (EKF)

Нелинейная система


$$\begin{aligned}x_t &= g(u_t, x_{t-1}) + \varepsilon_t \\z_t &= h(x_t) + \delta_t\end{aligned}$$

ЕКФ. Линеаризация

Нелинейность динамики

Обозначим

$$g'(u_t, x_{t-1}) = \frac{\partial g(u_t, x_{t-1})}{\partial x_{t-1}}$$



Разложим в ряд Тейлора



$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + g'(u_t, \mu_{t-1})(x_{t-1} - \mu_{t-1}) = \\ g(u_t, \mu_{t-1}) + G_t(x_{t-1} - \mu_{t-1})$$

ЕКФ. Линеаризация

Нелинейность измерений

Обозначим

$$h'(x_t) = \frac{\partial h(x_t)}{\partial x_t}$$



Разложим в ряд Тейлора

$$\begin{aligned} h(x_t) &\approx h(\bar{\mu}_t) + h'(x_t)(x_t - \bar{\mu}_t) = \\ &h(\bar{\mu}_t) + H_t(x_{t-1} - \bar{\mu}_t) \end{aligned}$$

ЕКФ. Алгоритм

```

1:  Algorithm Extended_Kalman_filter( $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$ ):
2:       $\bar{\mu}_t = g(u_t, \mu_{t-1})$ 
3:       $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t$ 
4:       $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$ 
5:       $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$ 
6:       $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$ 
7:      return  $\mu_t, \Sigma_t$ 

```

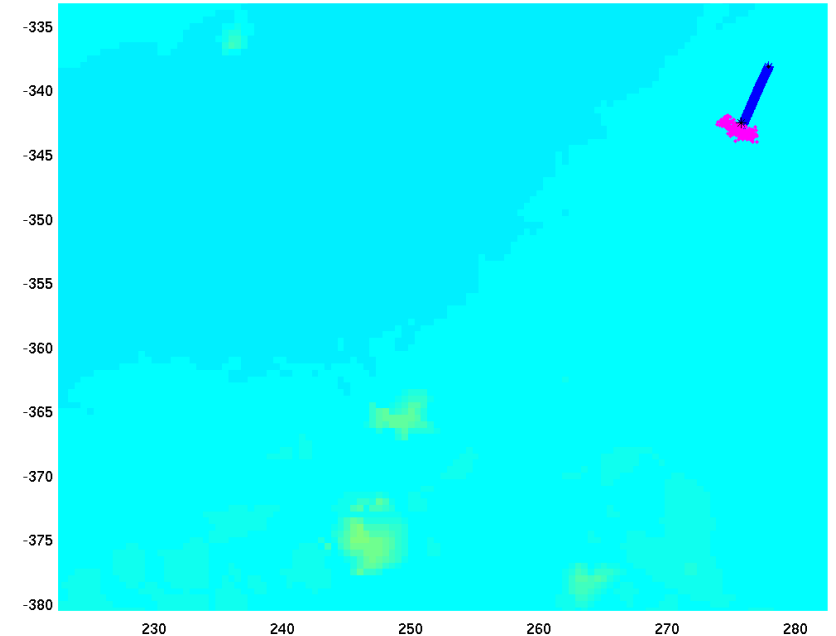
	Kalman filter	EKF
state prediction (Line 2)	$A_t \mu_{t-1} + B_t u_t$	$g(u_t, \mu_{t-1})$
measurement prediction (Line 5)	$C_t \bar{\mu}_t$	$h(\bar{\mu}_t)$

Фильтр частиц

Частицы:

$$\chi_t = x_t^{[1]}, x_t^{[2]}, \dots, x_t^{[m]}, \dots, x_t^{[M]}$$

$x_t^{[m]}$ ($1 \leq m \leq M$) – гипотеза о состоянии x в момент времени t



Фильтр частиц

$$x_t^{[m]} \sim p(x_t | z_{1:t}, u_{1:t})$$

```
1:  Algorithm Particle_filter( $\mathcal{X}_{t-1}, u_t, z_t$ ):  
2:     $\bar{\mathcal{X}}_t = \mathcal{X}_t = \emptyset$   
3:    for  $m = 1$  to  $M$  do  
4:      sample  $x_t^{[m]} \sim p(x_t | u_t, x_{t-1}^{[m]})$   
5:       $w_t^{[m]} = p(z_t | x_t^{[m]})$   
6:       $\bar{\mathcal{X}}_t = \bar{\mathcal{X}}_t + \langle x_t^{[m]}, w_t^{[m]} \rangle$   
7:    endfor  
8:    for  $m = 1$  to  $M$  do  
9:      draw  $i$  with probability  $\propto w_t^{[i]}$   
10:     add  $x_t^{[i]}$  to  $\mathcal{X}_t$   
11:    endfor  
12:    return  $\mathcal{X}_t$ 
```

Фильтр частиц

Альтернатива отсеву

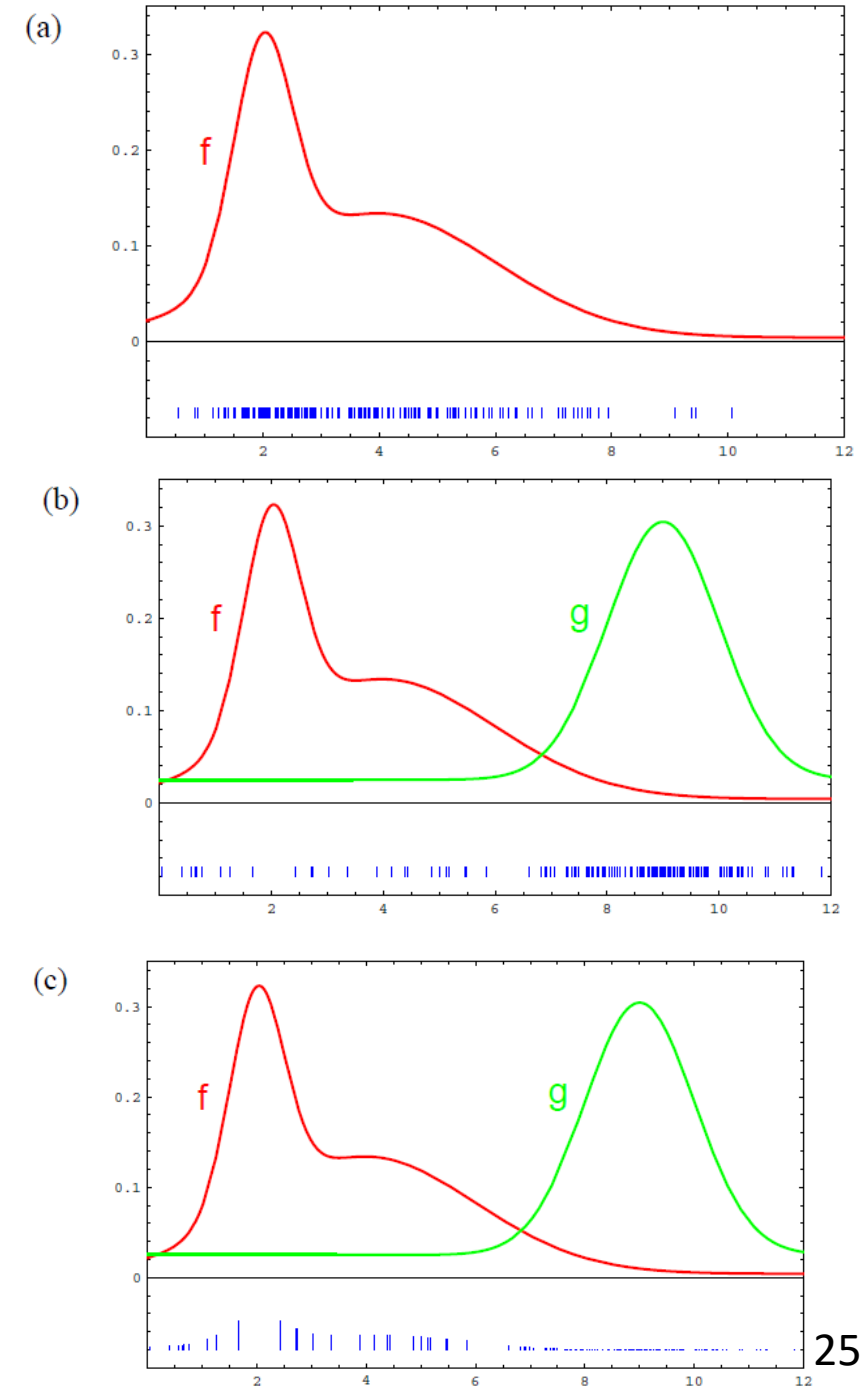
```
1:  Algorithm Particle_filter( $\mathcal{X}_{t-1}, u_t, z_t$ ):  
2:     $\bar{\mathcal{X}}_t = \mathcal{X}_t = \emptyset$   
3:    for  $m = 1$  to  $M$  do  
4:      sample  $x_t^{[m]} \sim p(x_t \mid u_t, x_{t-1}^{[m]})$   
5:       $w_t^{[m]} = p(z_t \mid x_t^{[m]})$   
6:       $\bar{\mathcal{X}}_t = \bar{\mathcal{X}}_t + \langle x_t^{[m]}, w_t^{[m]} \rangle$   
7:    endfor  
8:    for  $m = 1$  to  $M$  do  
9:      draw  $i$  with probability  $\propto w_t^{[i]}$   
10:     add  $x_t^{[i]}$  to  $\mathcal{X}_t$   
11:    endfor  
12:    return  $\mathcal{X}_t$ 
```

$$w_t^{[m]} = p(z_t \mid x_t^{[m]}) w_{t-1}^{[m]}$$

Фильтр частиц. Веса выборки

$$\frac{1}{M} \sum_{m=1}^M I(x^{[m]} \in A) \rightarrow \int_A g(x) dx$$
$$w^{[m]} = \frac{f(x^{[m]})}{g(x^{[m]})}$$

$$\left[\sum_{m=1}^M w^{[m]} \right]^{-1} \sum_{m=1}^M I(x^{[m]} \in A) w^{[m]} \rightarrow \int_A f(x) dx$$



Фильтр частиц. Математика

$$x_{0:t}^{[m]} = x_0^{[m]}, x_1^{[m]}, \dots, x_t^{[m]}$$

$$bel(x_{0:t}) = p(x_{0:t}|u_{1:t}, z_{1:t}) \text{ вместо } bel(x_t) = p(x_{0:t}|u_{1:t}, z_{1:t})$$

$$\begin{aligned} p(x_{0:t}|u_{1:t}, z_{1:t}) & \stackrel{Bayes}{=} \eta p(z_t|x_{0:t}, z_{1:t-1}, u_{1:t}) p(x_{0:t}|z_{1:t-1}, u_{1:t}) \\ & \stackrel{Markov}{=} \eta p(z_t|x_t) p(x_{0:t}|z_{1:t-1}, u_{1:t}) \\ & = \eta p(z_t|x_t) p(x_t|x_{0:t-1}, z_{1:t-1}, u_{1:t}) p(x_{0:t-1}|z_{1:t-1}, u_{1:t}) = \\ & \stackrel{Markov}{=} \eta p(z_t|x_t) p(x_t|x_{t-1}, u_t) p(x_{0:t-1}|u_{1:t-1}, z_{1:t-1}) \end{aligned}$$

Фильтр частиц. Математика

В момент времени $t - 1$ предполагаемое $x_t^{[m]}$ в соответствии с алгоритмом:

$$p(x_t|x_{t-1}, u_t)bel(x_{0:t-1}) = p(x_t|x_{t-1}, u_t)p(x_{0:t-1}|z_{0:t-1}, u_{0:t-1})$$

$$\begin{aligned} w^{[m]} &= \frac{\text{target distribution}}{\text{proposal distribution}} = \\ &= \frac{\eta p(z_t|x_t)p(x_t|x_{t-1}, u_t)p(x_{0:t-1}|u_{1:t-1}, z_{1:t-1})}{p(x_t|x_{t-1}, u_t)p(x_{0:t-1}|z_{0:t-1}, u_{0:t-1})} = \\ &= \eta p(z_t|x_t) \end{aligned}$$

Фильтр частиц. Математика

$$\eta w_t^{[m]} p(x_t | x_{t-1}, u_t) p(x_{0:t-1} | z_{0:t-1}, u_{0:t-1}) = bel(x_{0:t})$$

Фильтр частиц. Ошибки

- Конечное количество частиц
- Случайность повторной выборки

Фильтр частиц. Ошибки


- Конечное количество частиц
- Случайность отсева

$$w_t^{[m]} \begin{cases} 1 & \text{при повторной выборке} \\ p(z_t | x_t^{[m]}) w_{t-1}^m & \text{без повторной выборки} \end{cases}$$

Фильтр частиц. Ошибки

- Конечное количество частиц
- Случайность отсева

```
1: Algorithm Low_variance_sampler( $\mathcal{X}_t, \mathcal{W}_t$ ):  
2:    $\bar{\mathcal{X}}_t = \emptyset$   
3:    $r = \text{rand}(0; M^{-1})$   
4:    $c = w_t^{[1]}$   
5:    $i = 1$   
6:   for  $m = 1$  to  $M$  do  
7:      $u = r + (m - 1) \cdot M^{-1}$   
8:     while  $u > c$   
9:        $i = i + 1$   
10:       $c = c + w_t^{[i]}$   
11:    endwhile  
12:    add  $x_t^{[i]}$  to  $\bar{\mathcal{X}}_t$   
13:  endfor  
14:  return  $\bar{\mathcal{X}}_t$ 
```



$$i = \underset{j}{\operatorname{argmin}} \sum_{m=1}^j w_t^{[m]} \geq u$$

Фильтр частиц. Ошибки



- Конечное количество частиц
- Случайность отсева
- Различие между предполагаемым и целевым распределением

Фильтр частиц. Ошибки

- Конечное количество частиц
- Случайность отсева
- Различие между предполагаемым и целевым распределением
- Нехватка «хороших» частиц


Фильтр частиц. Пример

Инициализация



Фильтр частиц. Пример

Движение



Фильтр частиц. Пример

Измерение





```
measurement = Sqrt((orientierX - robotX)^2 + (orientierY - robotY)^2)
```

$$f(\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\mu - \mu_0)^2}{\sigma^2}}$$

```
S = Sum(weight)
for i in range(N):
    weight[i] = weight[i]/S
```

Фильтр частиц. Пример


Отсев



```
index = random.randint(0, 6)
betta = 0
for i in range(N):
    betta = betta + random.uniform(0, 2*max(weight))
    while betta > weight[index]:
        betta = betta - weight[index]
        index = (index + 1)%N # индекс изменяется в цикле от 0 до N
    newParticleList.append(particleList[index])
particleList = newParticleList
```

Фильтр частиц. Пример

Отсев



Фильтр частиц. Пример

Результат

```
estimateX = 0
estimateY = 0
for i in range(N):
    estimateX = estimateX + particleList[i].X*particleList[i].weight
    estimateY = estimateY + particleList[i].Y*particleList[i].weight
```

